



M Ű E G Y E T E M 1 7 8 2

Budapesti Műszaki és Gazdaságtudományi Egyetem

Villamosmérnöki és Informatikai Kar

Mesterséges Intelligencia és Rendszertervezés Tanszék

Szolár Soma

Szívsebészeti orvosi döntéstámogatás mellkas CT felvételek alapján

BSc Önálló Laboratórium Dokumentáció

Konzulensek:

Hadházi Dániel és Révy Gábor

Budapest, 2026

Tartalom

1. Összefoglalás.....	4
2. Bevezetés	4
2.1 Klinikai kontextus	4
2.2 Motiváció.....	4
3. Pipeline összefoglalás	4
4. Adathalmaz – ImageCHD.....	5
4.1 Az adathalmaz leírása	5
4.2 Az adathalmaz előnyei	5
4.3 Az adathalmaz hátrányai	5
5. Előfeldolgozás.....	6
5.1 Az előfeldolgozás szükségessége.....	6
5.2 Újra-mintavételezés	6
5.3 Orientáció-korrekció	6
6. Szegmentáció – TotalSegmentator	7
6.1 A TotalSegmentator bemutatása.....	7
6.2 A szegmentált struktúrák	7
6.3 Ground truth vs. TotalSegmentator szegmentációk.....	7
7. TS és ImageCHD határai	8
8. Érdekes régió (ROI) meghatározása	8
8.1 A ROI meghatározásának módszere	8
9. Lapszerűségi szűrés - Frangi-filter	8
9.1 Motiváció és elméleti háttér	8
9.2 A Hesse-mátrix	9
9.3 Főirányok és sajátértékek (Sajátértékek és geometriai értelmezés).....	9
9.4 Képlet és arányszámok (Frangi-egyenlet).....	9
9.5 Multiscale analízis	10
10. Kimenet első körben	10
.....	10
11. Csőszerűségi szűrés és vágósíkok	11
11.1 Az aorta és artéria mint vezérstruktúrák	11
11.2 A Frangi csőszerűségi szűrő	11
11.3 Vágósík meghatározása.....	11
11.4 Feature-ek előállítás.....	12
11.5 Cimkézés.....	13
11.6 ValveLocatorCNN – Hálózataarchitektúra és Képzési Stratégia	13


11.6.1	Bemeneti projekció (input_proj)	13
11.6.2	Kiterjesztett reziduális blokkok (blocks)	13
11.6.3	Kimeneti fej (head)	14
12.	Maszkolás és végső szegmentáció	14
12.1	Kombinált maszk	14
12.2	Eredmény értékelése.....	15
13.	Továbbfejlesztési lehetőségek	15
14.	Irodalomjegyzék.....	16

1. Összefoglalás

Ez a dokumentáció a szívsebészeti orvosi döntéstámogatás tárgyú önálló laboratóriumi munka eredményeit foglalja össze. A munka célja a kamra sövény automatikus detektálása mellkas CT felvételeken.

2. Bevezetés

2.1 Klinikai kontextus




1. ábra VSD

A szív kamrasövénye a jobb és bal kamrát elválasztó izom fal. Normális esetben ez a fal teljesen zárt, így a két kamra vérkeringése elkülönül. A VSD a leggyakoribb veleszületett szívfejlődési rendellenesség, amely a születési szívhibák közel 25-30%-át teszi ki. VSD esetén a septumban lévő nyíláson át a vér a magasabb nyomású bal kamrából a jobb kamrába áramlik, ami a tüdőkeringés túlterheléséhez, végső soron szívelégtelenséghez és más súlyos szövődményekhez vezet.

A VSD méretétől és elhelyezkedésétől függően különböző kezelési stratégiák léteznek. A pontos diagnózis és a sövény anatómiájának ismerete ezért kulcsfontosságú a sebészi tervezésben.

2.2 Motiváció



2. ábra Sövény szegmentáció, amin látszódik, hogy lyukas

Az VSD diagnosztika során az orvos manuálisan vizsgálja át a CT szeletek hosszú sorozatát, hogy azonosítsa a sövény defektust. Ez az eljárás időigényes és szubjektív. Az automatikus szegmentáció és detektálás célja a diagnózist segítő munkafolyamat gyorsítása, és olyan kvantitatív információ nyújtása (pl. defektus mérete, helyzetének meghatározása), amely jelenleg csak manuálisan és nagy változékonysággal érhető el.

Egyelőre a cél egy szegmentáció, ami alapján lehet mondani valamit a VSD jelenlétéről.

3. Pipeline összefoglalás

- A szív releváns régióinak (jobb és bal kamra, aorta, pulmonális artéria) szegmentálása egy modell segítségével.
- Region of interest (ROI) meghatározása a prediktált szegmentációkból.
- Frangi lapszerűségi szűrő alkalmazása a ROI-n belül a sövény jelöltek kiemelésére.
- ROI szűkítés: a csőszerű struktúrák (aorta, artéria) azonosítása és vágósíkok meghatározása a felesleges területek eltávolítására, erre egy CNN háló betanítása.
- Eredmény validálása.

4. Adathalmaz – ImageCHD

4.1 Az adathalmaz leírása

Az ImageCHD nyilvánosan elérhető adathalmazt használtam. Az adathalmaz főbb jellemzői az alábbi táblázatban foglalhatók össze:

Jellemző	Érték
Felvételek száma	110 CT sorozat (kontrasztanyagossal)
Szegmentált struktúrák	ground truth jobb kamra, bal kamra, aorta, pulmonális artéria szegmentációk
Jellemző	Kamra sövény defektus (VSD) - a legtöbb CT-n jelen van

4.2 Az adathalmaz előnyei

- A ground truth szegmentációknak köszönhetően egyszerűen tudtam ellenőrizni a szűrőm kimentét.
- A legtöbb CT VSD-s betegről készült, így a klinikai szempontból legérdekesebb eseteken nézhettem az eljárásom kimeneteit.
- A kontrasztanyag miatt a szívüregek jobb kontraszttal rendelkeznek, ami javítja a lapszűrő kimentét .

Fontos megjegyezni, hogy a pipeline a tervek szerint nem a ground truth annotációkat, hanem a TotalSegmentator automatikus szegmentációit használja bemeneti adatként, hiszen gt szegmentációk nem fognak rendelkezésre állni.

4.3 Az adathalmaz hátrányai

- Sok esetben rosszak voltak a gt szegmentációk, például a aorta nem ment bele a bal kamrába.
- Sok CT felvétel homályos, rossz minőségű volt.
- A nyers CT felvételek nem izotrópikusak és rossz orientációjúak.

5. Előfeldolgozás

5.1 Az előfeldolgozás szükségessége

A nem izotrópikusság miatt a voxelek térfogategységei különböző méretűek a három tengelyen. Ez komoly problémát jelent a három dimenziós képfeldolgozó algoritmusoknak (különösen a Hessian-alapú szűrőknek), amelyek egyenletes voxeltávolságot feltételeznek.

A rossz orientációja a kezdeti szegmentálást nehezíti meg, hiszen ezek a modellek standard CT felvételek alapján tanultak.

5.2 Újra-mintavételezés

Az első lépés a CT felvétel izotropikus újra-mintavételezése. A cél spacing minden dimenzióban $1 \times 1 \times 1$ mm.

Miért $1 \times 1 \times 1$ mm?


A Frangi-szűrő és a Hessian-alapú módszerek izotropikus térben adnak pontos eredményt. Eltérő voxelméret esetén az eigenvalue-k torzítottak lennének, és a lapszerűségi/csőszerűségi pontszámok megbízhatatlanná válnának.


A mintavételezési távolságok az adathalmazban levő excel táblázatban voltak megadva.

5.3 Orientáció-korrekción

Sok CT felvétel nem standard orientációban kerül tárolásra. Az anatómiai orientáció az alábbi konvenció szerint kerül helyreállításra: bal-jobb (L-R), elülső-hátsó (A-P), fejtetől lábig (S-I)

Eredmény:





6. Szegmentáció – TotalSegmentator

6.1 A TotalSegmentator bemutatása

A TotalSegmentator (TS) egy nnU-Net alapú automatikus szegmentáló modell. A projekt a TS által kínált szív-specifikus szegmentációs modult alkalmazza.

6.2 A szegmentált struktúrák

A TotalSegmentator kimenetéből az alábbi struktúrák kerülnek felhasználásra: két kamra, aorta, artéria


Ezek a szegmentációk a downstream lépések (ROI meghatározás, maszkolás, csőszerűség-alapú vágósíkok) bemeneteként szolgálnak.

6.3 Ground truth vs. TotalSegmentator szegmentációk


A fejlesztés jelenlegi fázisában a pipeline kipróbálása és debuggolása részben a ground truth annotációkkal történt. A végső cél azonban a TotalSegmentator szegmentációk kizárólagos alkalmazása, így a pipeline teljesen annotáció-mentes (annotation-free) lesz. Ez a cél különösen fontos, mert a klinikai alkalmazásban nincs manuális annotáció.

Megjegyzés a TS minőségéről

A TotalSegmentator szegmentációk a legtöbb esetben kellő minőségűek a sövény körülhatárolásához, de VSD-s esetekben a kamrák szegmentációja pontatlanabb lehet.



6. ábra GT szegmentáció



5. ábra TS szegmentáció

7. TS és ImageCHD határai

Megpróbáltam prediktálni mindegyik CT-re az ImageCHD-ból. Az eredeti, de beforgatott, HU normailzált (az értékek a CT-n -1000 és 1000 között vannak nagyrészt), helyes fejléccel rendelkezőket adtam be a TS-nek, amiben meg vannak a helyes spacingek.

De a TS nem adott jó szegmentációkat az ImageCHD 2/3-ára. Ennek oka lehet a domain shift, hogy nem VSD-s betegeken tanult, illetve a CT felvételek rossz minősége is közre játszhatott.

Így kénytelen voltam egy másik dataset-et, a lidc-t használni.

A lidc-ben 32 ct felvétel van, modellekkel prediktált szegmentációkkal, én a 604-es nnunet szegmentációit használtam.

8. Érdekes régió (ROI) meghatározása

A ROI szükségessége


A teljes CT kiterjedése nagy számú irreleváns struktúrát tartalmaz. Ezért a lapszűrés egy jól meghatározott régióra korlátozódik.

8.1 A ROI meghatározásának módszere


A régió meghatározása a TotalSegmentator által szegmentált két kamra uniójának befoglaló téglatestéből indul ki.

A ROI meghatározásának lépései:

1. Jobb és bal kamra felfűjása
2. Metszet képzése



8. ábra Jobb és bal kamra



7. ábra Metszet

9. Lapszerúségi szűrés - Frangi-filter

9.1 Motiváció és elméleti háttér

A kamra sővény lapszerű geometriával rendelkezik: két dimenzióban kiterjedt, a harmadikban vékony. A Frangi-filter eredetileg érelőhívó eljárásként vált ismertté, de általánosítható bármely geometriai primitív (lap, cső, gömb) kiemelésére a Hesse-mátrix sajátértékein alapuló pontozással.

9.2 A Hesse-mátrix

A Hesse-mátrix a kép második rendbeli parciális deriváltjait tartalmazza minden voxelre, ami az intenzitás lokális változásait jelenti. Egy adott x 3D-s pontban, skálakompenzációval az alábbi formában írható fel

$$\mathcal{H}(x, \sigma) = \sigma^{2\gamma} \cdot \begin{bmatrix} L(x) * \frac{\partial^2 G(x, \sigma)}{\partial x^2} & L(x) * \frac{\partial^2 G(x, \sigma)}{\partial x \partial y} & L(x) * \frac{\partial^2 G(x, \sigma)}{\partial x \partial z} \\ L(x) * \frac{\partial^2 G(x, \sigma)}{\partial y \partial x} & L(x) * \frac{\partial^2 G(x, \sigma)}{\partial y^2} & L(x) * \frac{\partial^2 G(x, \sigma)}{\partial y \partial z} \\ L(x) * \frac{\partial^2 G(x, \sigma)}{\partial z \partial x} & L(x) * \frac{\partial^2 G(x, \sigma)}{\partial z \partial y} & L(x) * \frac{\partial^2 G(x, \sigma)}{\partial z^2} \end{bmatrix}$$

Ahol a Gauss-kernel:

$$G(x, \sigma) = \frac{1}{\sqrt{(2\pi\sigma^2)^D}} e^{-\frac{\|x\|^2}{2\sigma^2}}$$

A $\sigma^{2\gamma}$ skálakompenzáció azért szükséges, mert nagy skála esetén a kép elmosódik, kicsi az amplitúdó, és alacsony intenzitás értékeket kapunk; a szorzó ezt kompenzálja.

9.3 Főirányok és sajátértékek (Sajátértékek és geometriai értelmezés)

A `np.linalg.eigh(H)` függvény segítségével a Hesse-mátrixból megkapjuk:

- azokat az irányokat (sajátvektorokat), amelyek irányába a leginkább vagy legkevésbé változik az intenzitás,
- és ezen irányokban az intenzitás változásokat (sajátértékek: $\lambda_1, \lambda_2, \lambda_3$).

Geometriai értelmezés: A mátrix egy lokális gömbkörnyezetet egy ellipszoiddá képez le. A voxelkörnyezet geometriai típusa a sajátértékek arányán múlik ($|\lambda_1| \leq |\lambda_2| \leq |\lambda_3|$ feltételezéssel):

Geometria	Feltétel	Értelmezés
Lap (sövény)	$\ \lambda_1\ \approx 0, \ \lambda_2\ \approx 0, \ \lambda_3\ \gg 0$	Két irányban lapos, egyben meredek változás
Cső (aorta)	$\ \lambda_1\ \approx 0, \ \lambda_2\ \approx \ \lambda_3\ \gg 0$	Egy irányban lapos, kettőben meredek
Gömb (szöveti csomó)	$\ \lambda_1\ \approx \ \lambda_2\ \approx \ \lambda_3\ $	Minden irányban meredek változás

9.4 Képlet és arányszámok (Frangi-egyenlet)

Az arányszámok és szorzótényezők alapján egy pontozó képlet kerül alkalmazásra:

$$\mathcal{R}_A = \frac{|\lambda_2|}{|\lambda_3|} \quad (\text{lap-csőszerűség})$$

$$\mathcal{R}_B = \frac{|\lambda_1|}{\sqrt{|\lambda_2\lambda_3|}} \quad (\text{gömbszerűség})$$

$$\mathcal{S} = \|\mathcal{H}\|_F = \sqrt{\sum_{j \leq D} \lambda_j^2} \quad (\text{struktúraintenzitás})$$

Pontozó képlet:

0	if $\lambda_3 < 0$
$\mathcal{V}_{plate} = e^{-\frac{\mathcal{R}_{plate}^2}{2\alpha^2}} \cdot e^{-\frac{\mathcal{R}_{blob}^2}{2\beta^2}} \cdot \left(1 - e^{-\frac{\mathcal{S}^2}{2c^2}}\right)$	egyébként


(ahol az α, β, c hangolható paraméterek)

A végső pontszám a legmagasabb értéket veszi fel a vizsgált σ -skálák felett (multiscale analízis).

9.5 Multiscale analízis

A sövény vastagsága felvételenként eltérő lehet. Ezért a szűrő több skálán (sigma értéken) fut, és a pontszám maximumát veszi skálánként. Ez biztosítja, hogy eltérő vastagságú sövények is detektálhatók legyenek.


10. Kimenet első körben



Látható, hogy olyan helyen is van kimenet, ahol az aorta és artéria van, pedig nem kéne. Ezért szűkíteni kell a ROI-t.

9. ábra Lapszűrés elsőre

11. Csőszerűségi szűrés és vágósíkok



Egy fajta vágósíkot képezhetünk a kamrák csőszerűvé változásának megfigyelésével. A síkhoz kell egy pont és egy normál vektor.

- Pont: ahol csőszerűvé válik a kamra.
- Normál vektor: amerre tovább megy a cső

Ötlet: lehetséges pontok és normál vektorok felajánlása NH-nak. Majd ő eldönti plusz egyéb információk alapján, melyik lesz a jó.

10. ábra Kívánt vágósík

11.1 Az aorta és artéria mint vezérstruktúrák

A sövény felső határa az aortagyök és a pulmonális artéria tövénél helyezkedik el. Ezek a struktúrák erősen csőszerű geometriával rendelkeznek. A csőszerűségi szűrő alkalmazásával meghatározható, hogy a sövényiszűrő melyik voxeloktól felfelé kezd csőszerű struktúrát jelölni ez a határ adja a vágósík helyzetét.

11.2 A Frangi csőszerűségi szűrő

A csőszerűségi pontozás ugyanazon a Hessian-alapú mechanizmuson alapul, mint a lapszerűségi szűrő, de eltérő sajátértékarányokat céloz.

Tubeless feltétele már ismertette volt.

A képlet így változik:


0	if $\lambda_2 > 0$ or $\lambda_3 > 0$
$\left(1 - e^{-\frac{R_A^2}{2\alpha^2}}\right) \cdot e^{-\frac{R_B^2}{2\beta^2}} \cdot \left(1 - e^{-\frac{S^2}{2c^2}}\right)$	egyébként

Itt is fontos, hogy több skálán futassunk.


11.3 Vágósík meghatározása

A vágósíkhhoz egy pont és egy normálvektor szükséges. A csőszerűségi pontszám alapján meghatározásra kerül, hogy a sövény mentén haladva mikor válik dominánssá a csőszerű struktúra egy betnítt háló által. Ennél a pozíciónál egy sík kerül illesztésre, amelynek normálvektora a csőtengellyel párhuzamos. Ez a sík vágja le a szegmentációból a felesleges (nem-sövény) területeket.


11.4 Feature-ek előállítása



11. ábra Bal kamra és aorta





12. ábra Bal kamra + aorta alja



13. ábra Szkeleton

- Fogjuk a kamrát és a rá csatlakozó csőszerű struktúrának alsó részét.
- Vegyük ezek unióját.
- Szkeletonizáljuk
- Vegyük a szkeleton két legtávolabbi pontja közti legrövidebb utat, így megkapva az alakzat fő vonalát.
- A fővonal felső 10%-ban megmérjük a sugarakat.
- A sugarak alapján veszünk dinamikus szigmákat.
- Ezen a fővonalon lefuttathatjuk a csőszerűség szűrést a dinamikus szigmákkal. -> csőszerűségi értékek és saját vektorok

11.5 Cimkézés



A tanításhoz kellenek címkék is. Ezeket én határoztam meg egy parancssoros programmal, így:

- Beolvastam az adott CT-hez, adott kamra és csőhöz tartozó featur-eket.
- Kiplotoltam a feature-eket egymás alá a fő vonal index szerint.
- Beadtam egy vágási indexet.
- Ez alapján a vágási index alapján legeneráltam a síkot és kiplotoltam, hogy ez a sík az adott CT-n hogyan nézne ki.
- Ha jónak láttam, akkor mentem tovább a következőre, ha nem, akkor újra kiplotoltam a featur-eket.

11.6 ValveLocatorCNN – Hálózataarchitektúra és Képzési Stratégia

Ez egy kiterjesztett 1D-CNN architektúra. Ez a Temporal Convolutional Network (TCN) stílusú, Seq2Seq (szekvenciából szekvenciába) modell 100 időlépésből álló ablakokat dolgoz fel, és közvetlenül pozíciónkénti logitokat ad vissza a szelepek lokalizációjához.

Bemenet: (Batch, 100, N_features) – (Páciens, Idősor hossza, Jellemzők)

Belső CNN formátum (Transpose után): (Batch, N_features, 100) – Channels-First elrendezés

Kimenet (Squeeze után): (Batch, 100) – Logit értékek minden egyes pozícióhoz

11.6.1 Bemeneti projekció (input_proj)

A bemeneti réteg a kiindulási jellemzőtér (N_features) dimenzióit egy fix, belső rejtett csatornaméretre (alapértelmezetten 32) képezi le.

Rétegstruktúra: Conv1d(N_features -> 32, kernel_size=1) -> GELU

11.6.2 Kiterjesztett reziduális blokkok (blocks)

A hálózat magját öt darab, exponenciálisan növekvő látótávolságú (receptive field) reziduális blokk alkotja. A kiterjesztett (dilated) konvolúcióknak köszönhetően a hálózat anélkül képes nagy kontextust befogni, hogy a paraméterszám drasztikusan megnőne. Az összesített látótávolság a hálózat végére eléri a 63 pontot ($1 + 2 \times (1 + 2 + 4 + 8 + 16)$).

Egy blokk belső felépítése: Conv1d(dilation=d, kernel_size=3, padding=d) -> GELU -> Dropout(0.2) -> Conv1d(kernel_size=1) -> Reziduális kapcsolat (+x) -> GroupNorm

A padding = dilation beállítás garantálja a sértetlen szekvenciahossz megtartását, így téve lehetővé a reziduális összeadást.

11.6.3 Kimeneti fej (head)

Az utolsó réteg a 32 csatornás belső reprezentációt időlépésenként egyetlen kimeneti logittá tömöríti vissza, majd a csatornadimenzió kiürítésével kialakítja a végső predikciós formátumot.

Rétegstruktúra: Conv1d(32 -> 1, kernel_size=1) -> squeeze(1)

11.6.4 Paraméterszám és Tanítási Folyamat

Modell: A modell összesen nagyjából 21 000 paramétert tartalmaz (32 csatornás beállítás mellett). A viszonylag alacsony paraméterszám fontos volt, hogy a 30 mintát tartalmazó, kisméretű adathalmazon elkerüljem a túltanulást. Ezen kívül Dropout rétegekkel és a kis hálómérettel próbáltam elkerülni.

Veszteségfüggvény: BCEWithLogitsLoss

Kompenzálás: Mivel a vágási pontot jelölő pozitív pontok száma elenyésző a háttérhez képest, a veszteségfüggvény egy dinamikusan kiszámított pos_weight büntetősúlyt kap. Ez biztosítja, hogy a hálózat számára egy valódi vágási hely eltévesztése sokszorosan súlyosabb büntetést jelentsen, mint egy téves pozitív jelzés a háttérben.

Optimalizáció: A súlyfrissítésért az AdamW optimalizáló felel.

Tanulási ráta: A CosineAnnealingLR tanulási ráta ütemező. A tanítás elején nagyobb lépésekkel engedi a tér felfedezését, majd a tanulás végére koszinuszgörbe mentén csökkenti a lépésközt a precíz finomhangolás érdekében.

Túl tanulás ellen: A modellképzés egy 20 epochos türelmi idejű Early Stopping mechanizmussal van ellátva. Ez automatikusan leállítja a folyamatot, ha a validációs veszteség már nem javul. A legjobb validációs teljesítményt nyújtó iteráció súlyai kerülnek mentésre.


12. Maszkolás és végső szegmentáció

12.1 Kombinált maszk

Az alábbi maszkokat kombináljuk:


- A jobb és bal kamra szegmentáció uniójának bővített maszkja (dilation).
- A háló által meghatározott vágósík feletti területek kizárása.

A lapszerűségi pontszámot ezután csak az érvényes maszkba eső voxelekre tartjuk meg, majd küszöböljük (threshold) egy bináris maszkká.




14. ábra Eredmény a végső maszkkal

12.2 Eredmény értékelése



16. ábra Bal kamra a jobb kamra szemszögéből



15. ábra Szűrési kimenet 3D-ben

Zöld:GT bal kamra

Piros: Azok a helyek ahol a jobb és a bal kamra összeér

Fehér: szűrési eredmény

A kimenet még elég zajos, de vannak olyan átfolyások amiket láthatóvá tesz

13. Továbbfejlesztési lehetőségek

- **Kizárólag prediktált szegmentációk**

Ez teszi a pipeline-t teljesen automatikussá, és lehetővé teszi tetszőleges új CT felvételek feldolgozását manuális beavatkozás nélkül. Esetleg saját nnunet fine-tune-olása az ImageCHD-n.

- **Paraméterhangolás**

A Frangi-szűrő alpha, beta, c paramétereinek szisztematikus optimalizálása. Jelenleg ezek próbálkozások nyomán meghatározottak.

- **Kvantitatív kiértékelés**

Ezzel a pipeline teljesítménye számszerűsíthetővé válik és összehasonlítható más módszerekkel.

14. Irodalomjegyzék

- [1] Frangi, A.F., Niessen, W.J., Vincken, K.L., Viergever, M.A. (1998). Multiscale vessel enhancement filtering. In Medical Image Computing and Computer-Assisted Intervention (MICCAI), Lecture Notes in Computer Science, vol. 1496, pp. 130–137.
- [2] Wasserthal, J., et al. (2023). TotalSegmentator: Robust Segmentation of 104 Anatomic Structures in CT Images. Radiology: Artificial Intelligence, 5(5), e230024.
- [3] Zhang, Z., et al. (2021). ImageCHD: A 3D Computed Tomography Image Dataset for Classification of Congenital Heart Disease. In Medical Image Computing and Computer-Assisted Intervention (MICCAI), Lecture Notes in Computer Science, vol. 12905.